无创产前筛查 NIPT 多因素建模与分层检测时点优化、染色体异常判别研究

2026 年 8 月 4 日

摘要

无创产前检测（NIPT）是当前筛查胎儿染色体非整倍体的核心技术，胎儿游离 DNA 浓度、检测时点选择、异常判别精度直接决定筛查有效性。本文围绕男胎 Y 染色体浓度影响因素、BMI 分层最优检测时点、多协变量拓展优化、女胎异常判别四大核心问题，构建从统计推断到预测建模的完整分析体系。

针对问题一，首先采用 Pearson 相关系数系统筛查 18 项候选指标与 Y 染色体浓度的线性关联，识别出 X 染色体浓度、孕周、孕妇 BMI 等 12 项显著相关指标，其中 X 染色体浓度相关性最强（$r = 0.5362$）。针对同一孕妇多次纵向重复测量数据，构建三次 B 样条线性混合效应模型，引入孕妇随机截距校正个体基线异质性，似然比检验证实总孕周天数、孕妇 BMI 对 Y 染色体浓度均存在高度显著的非线性效应。进一步搭建广义加性模型（GAM）与正则随机森林开展横断面预测对比，多模型横向验证表明非线性模型泛化性能显著优于传统线性回归，随机森林测试集 R^2 达 0.3083，特征重要度排序与生物学机理完全一致[3][9]。

针对问题二，聚焦 BMI 分层最优 NIPT 采血时点，采用数据驱动的四分位数分组方案避免主观偏差。对比分组独立分位数回归与全局联合分位数回归两类方案，最终选用含孕周二次项与 BMI 交互项的全局分位数回归模型。设置 80% 90% 共 6 组达标概率阈值，基于「全组有效解 + 最大化组间极差」双层择优准则，确定 82% 为最优达标概率，输出四组 BMI 区间对应的最优检测孕周，呈现 BMI 越高、推荐检测时点越晚的单调规律，符合血浆稀释效应理论。进一步通过临界阈值扰动开展敏感性分析，证实高 BMI 人群对测序测量误差耐受度显著更低。

针对问题三，拓展纳入孕妇年龄、身高协变量构建多因素分位数回归模型，固定协变量均值后仍按 BMI 分层输出结果。双层择优后选定 86% 为最优达标概率，组间孕周极差达 11.17 周，分层区分度优于问题二简化模型。与问题二结果横向对比表明，忽略年龄、身高因素会系统性低估高 BMI 人群的检测时点延后幅度，多因素模型结论可靠性更高。

针对问题四，针对女胎无 Y 染色体辅助信号的检测难点，整合染色体 Z 值、GC 含量、测序读段参数、孕妇 BMI 共 12 项特征，同步训练可解释逻辑回归与非线性 XGBoost 两类模型。5 组随机种子重复实验表明，逻辑回归 AUC 区间为 0.6998 0.8288，稳定性优于 XGBoost；特征重要度分析显示测序 GC 偏差、BMI 稀释效应的贡献度显著高于单纯 Z 值信号。最终输出标准化逻辑回归判别方程与完整临床判定流程，为女胎染色体非整倍体筛查提供定量依据。

本文所有模型均基于真实测序数据构建，结论符合临床生物学机理，可为 NIPT 分层筛查策略优化、检测质量提升提供量化支撑。

关键词：无创产前筛查；分位数回归；广义加性模型；逻辑回归；XGBoost

1 问题重述与建模思路

1.1 问题背景

无创产前检测通过采集孕妇外周血提取胎儿游离 DNA，采用高通量测序技术判断胎儿染色体非整倍体风险，具有无创、准确率高的优势，已成为产前筛查主流方案。胎儿游离 DNA 浓度是决定检测有效性的核心指标，浓度过低会导致假阴性结果；同时检测孕周、孕妇体重指数、测序质量等多重因素均会干扰检测结果。针对男胎可利用 Y 染色体浓度辅助评估，而女胎缺乏性别特异性标记，筛查难度更高。

1.2 问题拆解

1. 问题一：分析 Y 染色体浓度与孕妇各项生理指标、测序指标的相关性，构建浓度预测模型，揭示各因素的作用规律；2. 问题二：按 BMI 对孕妇分层，求解不同组别达到 4% 浓度阈值的最优检测孕周，评估测量误差对结果的影响；3. 问题三：综合年龄、身高等更多因素，优化最优检测时点模型，提升分层推荐精度；4. 问题四：针对女胎样本，构建染色体非整倍体判别模型，给出可落地的判定方法。

1.3 模型基本假设

1. 假设测序数据经过标准化预处理，批次效应已得到校正，不同样本检测结果具有可比性；2. 假设胎儿染色体异常仅为 13、18、21 号三体，不存在其他罕见染色体结构变异；3. 假设孕妇孕周计算准确，无末次月经记录偏差导致的孕周错配；4. 假设 BMI 分组内孕妇具有相似的血浆稀释特征，组间差异显著大于组内差异；5. 假设缺失的 BMI 数据为随机缺失，采用中位数填充不会引入系统性偏差。

1.4 符号说明

表 1: 核心变量符号定义表

符号	含义
Y	Y 染色体浓度（胎儿游离 DNA 占比）
$Z_{13}, Z_{18}, Z_{21}, Z_X$	对应染色体 Z-score 值
$GC_{13}, GC_{18}, GC_{21}$	对应染色体 GC 含量
w	检测孕周（周）
BMI	孕妇身体质量指数
R_{raw}	原始测序读段数
R_{align}	参考基因组比对比例
R_{dup}	重复读段比例
R_{unique}	唯一比对读段数
P	染色体非整倍体预测概率
β_0	模型截距项
u_i	第 i 名孕妇的随机截距
ε	模型随机残差

2 问题 1 胎儿 Y 染色体浓度与孕妇相关指标相关性分析及关系模型构建

2.1 数据预处理

原始数据包含孕妇基本信息、测序质控指标、染色体 Z 值、浓度指标四大类共 20 余项变量。首先对字段名进行空格清洗，统一变量命名；对孕周字符串格式进行正则解析，转换为连续浮点数值；对存在缺失的孕妇 BMI 采用样本中位数填充，确保样本量不损失，全程严格遵循「不删行、仅删列」的特征筛选原则。

2.2 Pearson 相关性分析

采用 Pearson 积矩相关系数量化各变量与 Y 染色体浓度的线性关联强度，检验水准 $\alpha = 0.05$，$P < 0.05$ 认为存在统计学相关性，显著性标记规则：$P < 0.05$ 标记 *，$P < 0.01$ 标记 **，$P < 0.001$ 标记 ***。

2.2.1 显著相关变量结果

表 2: Y 染色体浓度显著相关指标统计

变量名称	Pearson 相关系数	P 值
X 染色体浓度	0.5362^{***}	< 0.0001
18 号染色体的 Z 值	-0.1806^{***}	< 0.0001
体重	-0.1572^{***}	< 0.0001
孕妇 BMI	-0.1518^{***}	< 0.0001
week_num	0.1251^{**}	0.0005
在参考基因组上比对的比例	-0.1148^{**}	0.0013
重复读段的比例	0.1075^{**}	0.0026
X 染色体的 Z 值	-0.1054^{**}	0.0032
13 号染色体的 Z 值	-0.1001^{**}	0.0051
唯一比对的读段数	-0.0996^{**}	0.0053
原始读段数	-0.0939^{**}	0.0086
年龄	-0.0871^{*}	0.0150

结果分析：正向相关变量中，X 染色体浓度与 Y 染色体浓度呈中等强度正相关，二者同属胎儿游离 DNA 测序计数指标，天然存在基因组耦合性，符合生物学预期；检测孕周与重复读段比例呈弱正相关，随孕周增加胎儿游离 DNA 占比逐步上升，与临床认知一致。负向相关变量涵盖 BMI、体重、测序比对类指标，其中 BMI、体重负相关印证了肥胖孕妇血容量更大、胎儿 DNA 被稀释的经典理论；测序读段类指标负相关提示测序总量提升并不直接增加胎儿浓度占比。

除 X 染色体浓度外，其余所有显著变量相关系数绝对值均小于 0.2，线性关联强度较弱，提示变量间普遍存在非线性作用关系，单纯线性模型不足以充分刻画数据规律，为后续非线性建模提供了先验依据。

2.2.2 无统计学意义相关变量

表 3: 无统计学显著性的相关指标

变量名称	Pearson 相关系数	P 值
身高	−0.0619	0.0838
怀孕次数	−0.0579	0.1061
被过滤掉读段数的比例	0.0403	0.2601
18 号染色体的 GC 含量	−0.0177	0.6223
13 号染色体的 GC 含量	−0.0174	0.6282
生产次数	0.0077	0.8292
21 号染色体的 Z 值	0.0065	0.8553
GC 含量	0.0043	0.9054
21 号染色体的 GC 含量	0.0022	0.9509
Y 染色体的 Z 值	0.0001	0.9982

上述变量 P 值均大于 0.05，在当前样本下未观测到与 Y 染色体浓度存在统计学意义的线性关联。其中各类染色体 GC 含量单变量相关性极弱，但后续多变量模型中仍可能通过校正测序偏差发挥作用，因此暂不直接剔除，纳入后续共线性诊断统一筛选。

2.3 多重共线性检验与变量预处理

相关性结果显示体重与 BMI 存在天然数学关联：BMI = 体重/身高^2，二者高度共线性，若同时纳入模型会造成系数挤压、符号异常。BMI 是临床通用的标准化肥胖评价指标，不受身高尺度干扰，解释性更强，因此后续建模统一剔除体重变量，仅保留 BMI 作为肥胖代表指标。

测序读段类指标（原始读段数、唯一比对读段数、比对比例）之间同样存在强共线性，原始读段数越高，唯一比对读段数同步升高，VIF 值普遍超过 100，存在极端多重共线性。后续建模中保留代表性指标，避免参数估计失真。

2.4 纵向重复测量：B 样条混合效应模型

2.4.1 模型构建背景

原始数据集包含同一孕妇多次随访采血记录，同一孕妇的多次观测之间存在自相关性，不满足普通回归模型的独立同分布假设，若直接使用横断面模型会低估标准误、夸大统计显著性。因此针对纵向数据采用混合效应模型框架，既能校正个体异质性，又能刻画变量的非线性趋势。

2.4.2 模型形式设定

采用三次 B 样条基函数拟合孕周与 BMI 的非线性效应，引入孕妇代码作为分组变量构建随机截距模型，模型形式如下：

$$\text{Y 染色体浓度}_{ij} = \beta_0 + f_1(\text{total}_d ays\text{total}_d ays_{\text{total}_d ays\text{total}_d ays_{ij})+f_2(\text{BMI}_{ij})+u_i+\varepsilon_{ij}} u_i \sim N(0,\sigma_u^2)\varepsilon_{ij} \sim N(0,\sigma_\varepsilon^2) \tag{1}$$

其中下标 i 代表第 i 名孕妇，j 代表该孕妇的第 j 次检测记录；f_1, f_2 为三次 B 样条平滑函数；u_i 为孕妇个体随机截距，反映不同孕妇的基线浓度差异；ε_{ij} 为模型残差。

样条自由度设置为 6，在拟合精度与模型复杂度之间取得平衡；模型采用极大似然法（ML）进行参数估计，便于后续嵌套模型似然比检验。

2.4.3 样本概况

本次建模共纳入 1081 条有效观测记录，覆盖 267 名孕妇，人均检测次数约 4 次，符合纵向重复测量数据结构特征。

2.4.4 非线性效应显著性检验

通过构建嵌套模型进行似然比检验，依次加入变量的非线性项，检验变量整体效应的统计学显著性，结果如下：- 总孕周天数：$\chi^2 = 357.2778$，自由度 $df = 5$，$P < 0.0001$，非线性效应高度显著；- 孕妇 BMI：$\chi^2 = 15.2032$，自由度 $df = 5$，$P = 0.0095$，非线性效应具有统计学显著性。

随机截距方差 Group Var = 0.001，组内相关系数大于 0，证实孕妇个体基线水平确实存在异质性，引入随机效应项具有必要性，纵向模型相比横断面模型推断更加可靠。

2.4.5 方法说明与定位

本 B 样条混合模型未施加光滑惩罚，与基于薄板回归样条的标准 GAMM 存在方法学差异，模型定位为统计推断工具，主要用于定性判断变量非线性效应的存在性与作用方向，不作为高精度预测工具使用。预测任务由后续横断面模型承担。

2.5 横断面预测探索：广义加性模型

2.5.1 模型原理

传统线性回归假设自变量与因变量呈固定线性关系，难以刻画复杂的非线性作用规律。广义加性模型（GAM）通过惩罚样条平滑函数对每个自变量分别进行非线性拟合，无需预先设定函数形式，能够自适应捕捉变量的曲线趋势，模型通用形式为：

$$g(E(Y)) = \beta_0 + \sum s_j(x_j) \tag{2}$$

其中 $g(\cdot)$ 为连接函数，本研究因变量为连续型浓度值，采用恒等连接；$s_j(\cdot)$ 为惩罚回归样条平滑项。

局限性说明：横断面 GAM 将所有观测视为独立样本，未校正同一孕妇重复测量的自相关性，因此统计推断效力弱于纵向混合效应模型，主要用于探索多变量联合非线性规律与预测性能对比。

2.5.2 变量筛选与最终模型

以 Pearson 相关性显著变量作为初始候选集，逐步剔除平滑项不显著的变量，同时考虑多重共线性剔除冗余指标，最终精简模型纳入 4 项核心变量：X 染色体浓度、检测孕周、孕妇 BMI、孕妇年龄。模型形式为：

$$\begin{aligned} \text{Y 染色体浓度} = \beta_0 &+ s(\text{X 染色体浓度}) + s(\text{week_num}) \\ &+ s(\text{孕妇 BMI}) + s(\text{年龄}) + \varepsilon \end{aligned} \tag{3}$$

数据集按 8:2 比例随机划分为训练集与测试集，固定随机种子 42 保证所有模型划分一致，结果可复现。普通线性 GAM 训练集 $R^2 = 0.4912$，训练集 RMSE=0.0245；测试集 $R^2 = 0.2949$，测试集 RMSE=0.0253。Logit 变换 GAM 训练集 $R^2 = 0.4571$，测试集 $R^2 = 0.2838$，性能略低于普通 GAM。

2.5.3 偏依赖效应分析

各变量对 Y 染色体浓度的偏依赖效应曲线呈现出明显的非线性特征，逐项分析如下：1. **X 染色体浓度 **：整体呈显著正向非线性趋势，低浓度区间上升斜率较大，高浓度区间增速放缓，呈现边际递减规律，是所有变量中影响强度最高的指标；2. ** 检测孕周 **：整体呈正向非线性效应，孕早期浓度快速上升，孕中期上升速率趋于平稳，与游离胎儿 DNA 随孕周累积的生物学规律完全吻合；3. ** 孕妇 BMI**：整体呈负向非线性效应，低 BMI 区间浓度下降平缓，BMI 超过临界值后浓度加速下降，印证了肥胖对胎儿 DNA 的稀释效应具有非线性放大特征；4. ** 孕妇年龄 **：效应曲线呈现复杂波动形态，不存在简单单调增减关系，提示年龄对 Y 染色体浓度的调控机制较为复杂，可能通过多重生理通路共同发挥作用。

2.6 随机森林回归模型

2.6.1 模型构建

为进一步验证非线性模型的稳健性，构建正则约束随机森林回归模型作为黑箱基准，自变量与最终 GAM 模型保持一致，通过袋外误差估计最优树数量与节点分裂参数，控制过拟合风险。

2.6.2 性能结果

随机森林训练集 $R^2 = 0.6131$，测试集 $R^2 = 0.3083$，测试集 RMSE=0.0251，泛化性能略优于 GAM 模型。训练集与测试集性能存在一定差距，表明数据本身噪声较强，模型存在轻度过拟合。

2.6.3 特征重要性

基于基尼指数计算特征重要度，排序结果如下：1. X 染色体浓度：0.6951，绝对主导地位；2. 检测孕周：0.1432，第二重要因素；3. 孕妇 BMI：0.1217，贡献度与孕周接近；4. 年龄：0.0400，影响相对较弱。

特征重要度排序与 GAM 偏依赖效应强度、Pearson 相关系数大小完全一致，从多个角度验证了变量作用规律的稳健性。

2.7 多模型横向对比

为系统评估不同建模策略的优劣，依次构建基础多元线性回归、对数变换模型、平方根变换模型、二次多项式模型、混合参数模型、普通 GAM、Logit-GAM、随机森林共 8 类模型，统一在相同训练测试划分下评估泛化性能。

表 4: 各模型样本外泛化性能汇总对比

模型	测试集 R^2	测试集 RMSE
正则随机森林	0.3083	0.0251
普通线性广义可加模型 (GAM)	0.2949	0.0253
Logit 变换广义可加模型 (Logit-GAM)	0.2838	0.0255
一次 + 二次多项式模型	0.2578	0.0260
原始 + 对数项模型	0.2575	0.0260
基础多元线性回归	0.2475	0.0262
一次 + 对数 + 二次混合参数模型	0.2290	0.0265
原始 + 平方根项模型	0.2199	0.0266

从统计理论角度，Y 染色体浓度为取值于 (0,1) 区间的比例数据，采用 logit 变换构建模型更加契合数据分布特征，但实证结果显示 Logit-GAM 泛化指标略低于普通线性 GAM，原因在于本数据集浓度值集中于狭窄区间，logit 变换的分布矫正收益不足以抵消变换引入的噪声。

综合拟合精度、可解释性、生物学解读便利性三个维度，本文选取普通线性广义可加模型作为横断面分析核心模型，同时将 Logit-GAM 作为机理驱动备选模型纳入对比，用以验证结论稳健性。随机森林作为性能上限参照，用于验证非线性建模的收益边界。

2.8 两套建模框架分工说明

本文同时采用纵向混合效应模型与横断面预测模型两套框架，二者目标、适用数据、定位互不相同，结论可以相互印证但不可混用：1. ** 纵向 B 样条混合模型 **：面向重复观测原始数据，核心价值是统计推断，回答「变量是否有作用、作用是否非线性」的问题，校正了个体自相关，结论统计学可靠性更高，但纳入变量有限，不用于高精度预测；2. ** 横断面 GAM 与随机森林 **：暂时忽略重复测量结构，核心价值是预测与多变量规律探索，回答「各变量贡献多大、预测精度多高」的问题，纳入变量更丰富，但统计推断需谨慎解读。

同时明确：本章节所有模型均使用全部采血时序观测记录，与问题 2、问题 3 采用的「每位孕妇首次达标事件」分析单元严格区分，数据口径不同，结论不可直接混用。

3 问题 2 基于 BMI 分组的最优 NIPT 检测时点研究

3.1 研究目标

临床研究表明，孕妇 BMI 是决定胎儿 Y 染色体浓度达到 4% 检测阈值的核心影响因素，不同 BMI 人群达到合格浓度的时间存在显著差异。本问题目标是对孕妇进行合理 BMI 分层，求解各组达到指定达标概率的最小检测孕周，给出差异化采血时点推荐，并评估检测误差对结论的扰动程度。

3.2 数据预处理与 BMI 分组方案

3.2.1 孕周数据清洗

原始孕周字段包含「13w」「13W+2」等多种字符串格式，采用正则表达式提取周数与天数，统一转换为以周为单位的浮点数值，确保时间尺度精确。剔除孕周异常、浓度缺失的无效样本，确保建模数据质量。

3.2.2 BMI 四分位数分组

为避免人为划分区间的主观偏差，采用数据驱动的四分位数分组方案，按样本 BMI 分布的 25%、50%、75% 分位数作为分组临界点，得到 4 组非等距 BMI 区间。该方案保证每组样本量大致均衡，分组结果完全由数据本身决定，不受主观判断影响。

最终四组 BMI 区间分别为：1. 第一组：$[20.70, 30.21)$，低 BMI 组；2. 第二组：$[30.21, 31.81)$，中低 BMI 组；3. 第三组：$[31.81, 33.93)$，中高 BMI 组；4. 第四组：$[33.93, 46.88]$，高 BMI 组。

每组选取区间中点作为代表性 BMI 数值，用于后续模型求解最优孕周。

3.3 模型迭代与方案优化

3.3.1 方案一：分组独立分位数回归（舍弃）

建模初期尝试对 4 个 BMI 分组分别构建独立的分位数回归模型，单独拟合每组内 Y 浓度随孕周的变化曲线。该方案优点是各组参数灵活，能够适配不同组的曲线形态；但缺陷十分突出：各组模型参数相互独立，无法共享全样本蕴含的生物学规律，小样本组参数估计波动极大，最优孕周结果出现无序震荡，高 BMI 组甚至出现违背稀释理论的异常结果。综合评估后舍弃该方案。

3.3.2 方案二：全局联合分位数回归（最终选用）

针对分组独立建模的缺陷，更换为全体样本统一训练的全局分位数回归框架。模型纳入孕周一次项、孕周二次项、孕妇 BMI 主效应，以及孕周与 BMI 的交互项，能够同时刻画浓度随孕周的非线性增长、BMI 的主效应稀释作用，以及 BMI 对增长速率的动态调节效应。模型形式如下：

$$Y_{\text{浓度}} = \beta_0 + \beta_1 w + \beta_2 w^2 + \beta_3 \text{BMI} + \beta_4 \cdot w \cdot \text{BMI}$$

其中 w 为检测孕周，β_4 为交互项系数，反映 BMI 对孕周增长速率的调节作用。

该方案优势在于：所有样本共同参与参数估计，信息利用率高，参数稳定性好；通过交互项自然体现 BMI 分层差异，无需分组独立建模；模型形式简洁，生物学解释清晰，便于后续求解最优孕周。

3.4 达标概率参数择优

3.4.1 候选参数设置

达标概率阈值无法依靠经验主观给定，需要通过量化筛选确定最优值。本文设置候选区间为 80% 90%，步长 2%，共 6 组达标概率，对应分位数分别为 0.20、0.18、0.16、0.14、0.12、0.10。分位数回归拟合指定分位点的浓度曲线，曲线上大于等于 4% 阈值的最小孕周即为对应达标概率下的最优检测时点。

3.4.2 双层筛选准则

本文设置「约束条件 + 择优目标」双层筛选准则：1. ** 硬性约束条件 **：四组 BMI 人群均能够求解得到处于合理临床孕周区间的有效最优解，不存在空值或极端异常值；2. ** 择优目标 **：在满足约束条件的候选参数中，最大化四组最优检测孕周的组间极差。

组间极差具备明确的临床含义：极差越大，说明模型区分不同 BMI 人群最佳检测窗口的能力越强，BMI 分层推荐策略的临床价值越高；若极差很小，说明分层与否差异不大，分层策略失去意义。

3.4.3 遍历结果与最优选择

依次对 6 组候选参数进行建模求解，结果汇总如下：- 置信水平 80%：四组均有有效解，组间孕周极差 9.40 周；- 置信水平 82%：四组均有有效解，组间孕周极差 11.35 周；- 置信水平 84%：四组均有有效解，组间孕周极差 8.88 周；- 置信水平 86%：四组均有有效解，组间孕周极差 9.75 周；- 置信水平 88%、90%：高 BMI 组不存在满足条件的有效孕周，出现空值，不满足基础约束，直接剔除。

在全部可行候选参数中，达标概率取 82% 时组间极差达到最大值，分层区分效果最优。综合以上量化筛选结果，最终确定采用 82% 作为基准达标概率约束。

> 说明：该择优策略并非单纯追求数值极值，而是在先保证方案临床可用性的前提下开展优选，规避单纯最大化指标带来的过拟合风险。后续通过阈值扰动敏感性分析进一步验证结论稳健性。

3.5 最优检测时点结果分析

在 82% 达标概率约束下，各组 BMI 对应的最优检测孕周结果如下表所示：

表 5: 不同 BMI 分组最优 NIPT 检测时点（82% 达标概率）

组别	BMI 区间	最优检测孕周（周）
1	[20.70, 30.21)	14.55
2	[30.21, 31.81)	16.11
3	[31.81, 33.93)	17.59
4	[33.93, 46.88]	25.90

结果呈现清晰的单调规律：孕妇 BMI 越高，推荐最优检测孕周持续延后。生理学解释为：BMI 升高会扩张母体血浆容量，胎儿游离 DNA 进入母体循环后被更大体积的血液稀释，同等孕周下浓度更低，因此需要等待更长孕周，让胎儿 DNA 持续累积，才能保证 82% 的概率超过 4% 检测阈值。

从组间差异看，低、中、中高三组之间最优孕周差距相对平缓，每组延后约 1.5 周；而最高 BMI 组相比第三组跃升超过 8 周，呈现明显的非线性跳变。这一现象表明稀释效应具备非线性特征，BMI

突破临界水平后，对检测窗口期的影响急剧放大，临床中对重度肥胖孕妇需要特别注意调整检测时间。

3.6 检测误差敏感性分析

3.6.1 扰动方案设计

测序偏差、样本采集波动、实验操作误差都会造成 Y 染色体浓度观测值存在测量误差，进而影响最优孕周求解结果。为评估结论的稳健性，将 4% 的临界浓度阈值在 $[0.037, 0.043]$ 区间内进行扰动，步长 0.001，固定 82% 达标概率模型，重新求解各组最优孕周，统计各组孕周波动幅度作为敏感性指标。

3.6.2 仿真结果汇总

各组对测量误差的敏感程度呈现显著差异，结果如下：1. ** 低 BMI 组 **：孕周波动幅度仅 0.02 周，几乎不受测量误差干扰，方案稳定性极高；2. ** 中低 BMI 组 **：孕周波动幅度 1.82 周，存在中等程度敏感度；3. ** 中高 BMI 组 **：孕周波动幅度 3.77 周，敏感度较高；4. ** 高 BMI 组 **：仅在阈值 0.037 0.040 区间存在有效解，阈值高于 0.040 后无可行孕周，对误差极度敏感。

3.6.3 临床启示

敏感性分析结果具有明确的临床指导意义：随着 BMI 升高，检测结果对测序测量误差的耐受能力持续下降。针对低 BMI 孕妇，常规质控标准即可保证检测时点推荐的可靠性；针对超重与肥胖孕妇，必须严格把控测序实验质控标准，降低测量误差，否则推荐的采血时点会出现大幅偏差，显著提升检测失败与假阴性风险。对于最高 BMI 区间人群，还应当预留备选检测窗口期，必要时采用二次采血复核策略。

4 问题 3 多因素作用下基于 BMI 分层的最优 NIPT 检测时点研究

4.1 研究拓展目标

问题二仅考虑了 BMI 单一因素，实际临床中孕妇年龄、身高、孕产史等多项特征都会影响胎儿游离 DNA 浓度。本问题在问题二基础上，综合纳入孕妇年龄、身高等协变量，构建拓展分位数回归模型，优化最优检测时点求解，进一步提升分层推荐精度。

4.2 变量筛选与模型构建

4.2.1 变量筛选依据

由问题一相关性分析可知，年龄与 Y 染色体浓度存在显著弱负相关，身高相关性接近临界值。考虑到 BMI 本身由身高体重计算得出，身高与 BMI 存在数学关联，若同时纳入身高主效应与 BMI 主效应会引入共线性。因此模型中身高仅作为控制变量纳入，不参与交互项，核心交互效应仍由孕周与 BMI 承担，既控制了身高混杂影响，又避免共线性问题。

最终纳入自变量：孕周一次项、孕周二次项、孕妇 BMI、孕妇年龄、孕妇身高、孕周 ×BMI 交互项。

4.2.2 拓展模型形式

构建多协变量分位数回归模型，形式如下：

$$Y_{\text{浓度}} = \beta_0 + \beta_1 w + \beta_2 w^2 + \beta_3 \text{BMI} + \beta_4 \text{年龄} + \beta_5 \text{身高} + \beta_6 w \cdot \text{BMI}$$

其中 w 为检测孕周，模型保留二次项刻画非线性增长趋势，保留交互项表征 BMI 对增长速率的动态调节作用，年龄、身高作为协变量校正基线水平。

求解最优检测窗口时，将年龄、身高固定为全体样本均值，仅保留孕周与 BMI 作为可变参数，保证最终结论仍按 BMI 分组输出，维持与问题二结果的横向可比性。

4.3 达标概率参数重新择优

沿用问题二的双层筛选准则，对拓展模型重新开展达标概率参数择优：1. ** 硬性约束 **：四组 BMI 分层均能求解得到处于合理临床区间 $[12, 26]$ 周的有效最优孕周，无缺失解；2. ** 择优目标 **：可行参数中最大化组间极差。

不同达标概率下各组最优孕周结果如下表：

表 6: 不同达标概率下各组最优 NIPT 孕周（多因素模型）

BMI 分组	80%	82%	84%	86%
$[20.70, 30.21)$	15.21	14.94	14.67	14.79
$[30.21, 31.81)$	15.91	15.88	16.20	17.94
$[31.81, 33.93)$	16.14	16.20	18.36	20.17
$[33.93, 46.88]$	22.40	23.32	25.57	25.96
组间极差	7.19	8.38	10.90	11.17

88%、90% 达标概率下高 BMI 组无可行检测窗口，不满足约束，直接剔除。在 4 组可行参数中，达标概率 0.86 时组间极差达到最大值 11.17 周，分层区分效果最优，因此最终选定 86% 作为多因素模型的基准达标概率。

4.4 最终推荐检测时点

在 86% 达标概率约束下，各组推荐最佳 NIPT 检测时点汇总如下：

表 7: 基于多因素模型的 BMI 分组最优检测时点

BMI 区间	代表 BMI	推荐最佳孕周（周）
$[20.70, 30.21)$	25.46	14.79
$[30.21, 31.81)$	31.01	17.94
$[31.81, 33.93)$	32.87	20.17
$[33.93, 46.88]$	40.40	25.96

整体规律与问题二保持一致：孕妇 BMI 越高，达到 86% 达标概率所需的检测孕周越晚，高 BMI 人群母体血容量更大，胎儿游离 DNA 稀释效应更强，需要更长时间累积。

4.5 检测误差敏感性分析

同样将临界浓度阈值在 $[0.037, 0.043]$ 区间扰动，评估多因素模型下结论的稳健性，结果如下：- 低 BMI 组：波动幅度 0.01 周，稳定性极高；- 中低 BMI 组：波动幅度 3.94 周，中等敏感度；- 中高 BMI 组：波动幅度 4.95 周，敏感度最高；- 高 BMI 组：仅阈值 ≤ 0.040 时存在可行窗口，高于该值无解。

敏感度规律与问题二完全一致，再次验证了「BMI 越高，对测量误差耐受度越低」的结论具有稳健性，不受模型是否纳入年龄身高因素的影响。

4.6 问题二与问题三结果横向对比

将两个问题的最优孕周结果进行横向对比，可以观察到以下差异：1. 低 BMI 组差异较小，多因素模型推荐时点略有延后，幅度在 0.2 周左右；2. 中高 BMI 组差异明显放大，多因素模型推荐时点比问题二延后 2 3 周；3. 整体而言，纳入年龄、身高协变量后，BMI 分层的组间差异更加显著，分层策略的临床价值进一步提升。

对比结果表明，仅依靠 BMI 单一因素的简化模型会系统性低估高 BMI 人群的检测时点延后幅度，存在假阴性风险。多因素模型考虑了更多个体异质性来源，结论可靠性更高，更适合用于精细化临床决策。

5 问题 4 女胎染色体非整倍体定量判定方法构建

5.1 研究难点与建模思路

男胎孕妇可以依托 Y 染色体浓度这一性别特异性标记，辅助评估胎儿游离 DNA 含量与检测质量；而女胎不携带 Y 染色体，缺乏独立的胎儿浓度参照指标，仅依靠各染色体 Z 值进行筛查更容易受到测序偏差、母体因素干扰，假阳性假阴性风险更高。

本问题针对女胎样本，以 13、18、21 号染色体非整倍体作为判定目标，综合 X 染色体 Z 值、GC 含量、测序读段参数、孕妇 BMI 等多维度信息，构建定量判别模型，形成可落地的异常判定方法。

建模测试流程设计如下：

1. 样本选取：直接读取女胎独立工作表数据，无需额外性别筛选；
2. 标签构建：染色体非整倍体字段非空标记为阳性 $y = 1$，空值标记为阴性 $y = 0$；
3. 特征集合：全面纳入 Z 值类、GC 含量类、测序读段类、孕妇指标四大类共 12 项候选特征；
4. 数据预处理：BMI 缺失采用中位数填充，所有特征进行标准化处理，保证模型系数可比；
5. 模型对比：同时训练逻辑回归（可解释线性模型）与 XGBoost（非线性树模型），设置多组随机种子重复实验，评估性能与稳定性；
6. 输出判定方案：结合模型结果给出概率计算公式与判定流程，形成完整方法。

5.2 Z 值生物学定义与意义

依据题目附录给出的标准定义，Z 值（Z-score）计算公式为：

$$Z = \frac{X - \mu}{\sigma} \tag{4}$$

其中 X 为待测样本目标染色体的相对读段比例，μ 为正常二倍体对照群体该染色体读段比例的均值，σ 为正常群体的标准差。

生物学机理：正常胎儿为二倍体，染色体拷贝数为 2，Z 值围绕 0 随机波动；三体样本染色体拷贝数为 3，目标染色体游离 DNA 占比升高，$X > \mu$，因此 $Z > 0$；单体样本拷贝数为 1，占比下降，$Z < 0$。因此 Z 值是识别染色体非整倍体的原生核心指标，具备明确的统计学与生物学意义。

尽管 Z 值是核心指标，但仅依靠单一 Z 阈值存在明显缺陷：测序 GC 偏差会系统性偏移读段比例，孕妇 BMI 会通过稀释效应影响浓度，这些干扰因素都会造成 Z 值异常但并非真正的染色体异常，进而导致假阳性。因此需要引入多变量联合校正，提升判别准确性。

5.3 特征筛选与多重共线性诊断

5.3.1 候选特征集合

初始候选特征涵盖四大类共 12 项指标：1. Z 值类：13 号染色体 Z 值、18 号染色体 Z 值、21 号染色体 Z 值、X 染色体 Z 值；2. GC 含量类：13 号染色体 GC 含量、18 号染色体 GC 含量、21 号染色体 GC 含量；3. 测序读段类：原始读段数、参考基因组比对比例、重复读段比例、唯一比对读段数；4. 孕妇指标：孕妇 BMI。

5.3.2 VIF 共线性诊断结果

采用方差膨胀因子（VIF）评估多重共线性程度，以 VIF>10 作为存在严重共线性的判断标准，诊断结果显示：- 三条染色体 GC 含量 VIF 值均达到数十万级别，存在极端多重共线性；- 原始读段数、唯一比对读段数、比对比例 VIF 值均超过一万，高度线性相关；- 四类 Z 值 VIF 均小于 3，共线性程度很低；- BMI 的 VIF 约为 127，与测序指标存在一定共线性。

5.3.3 筛选策略与最终特征集

遵循「保留核心生物学指标、剔除冗余测序指标、保留代表性校正项」的筛选原则：1. 全部 4 项 Z 值全部保留，作为判别核心信号；2. GC 含量三类中保留相关性最高的 13 号染色体 GC 含量，作为测序偏差校正代表；3. 测序读段类指标高度冗余，整体不纳入主模型，仅用于稳健性对比；4. 保留孕妇 BMI，纳入母体稀释效应校正。

最终建模特征集合为：13 号染色体 Z 值、18 号染色体 Z 值、21 号染色体 Z 值、X 染色体 Z 值、13 号染色体 GC 含量、孕妇 BMI。

5.4 实验设置

5.4.1 样本概况

女胎数据集共 605 条样本，其中染色体非整倍体阳性样本 67 条，阴性正常样本 538 条，正负样本比例约 1:8，存在显著类别不平衡。建模时采用类别权重策略缓解不平衡偏差。

5.4.2 评估方案

设置 5 组不同随机种子（6、10、22、33、42），每次按 75% 训练集、25% 测试集分层划分，保证训练测试集正负样本比例与整体一致。采用 5 折分层交叉验证进行超参数寻优，以 AUC 作为核心评价指标，兼顾模型区分能力与阈值无关性。

同时训练逻辑回归与 XGBoost 两类模型，前者侧重可解释性，能够输出显式判别公式；后者侧重预测性能，捕捉非线性交互效应，二者形成互补。

5.5 模型实验结果

5.5.1 AUC 性能汇总

多组随机种子下两类模型的测试集 AUC 结果如下表：

表 8: 女胎样本多随机种子模型 AUC 汇总

随机种子	逻辑回归 AUC	XGBoost 最优 AUC
6	0.7734	0.6414
10	0.7538	0.7085
22	0.6998	0.5712
33	0.8288	0.8153
42	0.7400	0.5669

结果分析：1. 逻辑回归 AUC 区间为 0.6998 0.8288，平均约 0.76，整体区分能力良好，且不同种子间波动相对较小，稳定性更优；2. XGBoost 最优单种子 AUC 可达 0.8153，上限略高于逻辑回归，但不同种子间波动极大，最低仅 0.5669，接近随机水平，稳定性很差；3. XGBoost 不稳定的根本原因在于阳性样本量偏少（仅 67 例），非线性模型参数多，容易在小样本下发生过拟合，导致泛化性能波动剧烈。

综合考虑临床应用对稳定性、可解释性的要求，最终选取逻辑回归作为主判定模型，XGBoost 作为辅助参照与非线性验证。

5.5.2 特征重要性分析

基于 XGBoost 多轮实验平均特征重要度，排序结果如下：

表 9: 特征平均重要度排序

特征	平均重要度
13 号染色体 GC 含量	0.3471
孕妇 BMI	0.2503
13 号染色体的 Z 值	0.1357
18 号染色体的 Z 值	0.1308
X 染色体的 Z 值	0.0858
21 号染色体的 Z 值	0.0502

重要度排名前两位均为干扰校正因素，而非传统认为的核心 Z 值指标。这一结果具有重要的临床启示：测序 GC 偏差与孕妇 BMI 稀释效应对检测结果的干扰程度，甚至超过了染色体拷贝数异常本身带来的 Z 值变化幅度。这也解释了为何单纯依靠 Z 阈值筛查会出现较多假阳性——很多 Z 值异常其实是测序偏差与母体因素导致的，并非真正的染色体异常。多变量联合模型能够分离这些干扰，因此判别更加准确。

5.6 标准化逻辑回归判定模型

5.6.1 回归方程

采用全部样本训练最终逻辑回归模型，基于标准化特征拟合得到对数几率形式的回归方程：

$$\begin{aligned}\operatorname{logit}(P) = &-0.4456 - 0.1926Z_{13} + 0.2077Z_{18} + 0.2247Z_{21} \\ &- 0.1409Z_X + 3.3633GC_{13} + 0.5242GC_{18} \\ &- 3.8788GC_{21} + 0.0990R_{\text{raw}} + 0.1132R_{\text{align}} \\ &- 0.2258R_{\text{dup}} - 0.1503R_{\text{unique}} - 0.2953\ \text{BMI}\end{aligned} \tag{5}$$

概率转换公式：

$$P = \frac{\exp\big(\operatorname{logit}(P)\big)}{1 + \exp\big(\operatorname{logit}(P)\big)} \tag{6}$$

其中 P 为样本存在 13/18/21 任意一类染色体非整倍体的预测概率，取值范围 0 到 1。

5.6.2 重要使用说明

该方程所有系数均基于标准化特征拟合得到，原始检测指标必须先执行标准化变换，再代入方程计算，直接代入原始数值会得到完全错误的结果。标准化参数（均值与标准差）由训练集统计得出，临床应用时需配套保存标准化参数表。

5.7 完整判定实施流程

基于上述模型，形成标准化的女胎染色体非整倍体判定流程，共四步：

1. 数据采集：采集待测孕妇的全部测序指标（各染色体 Z 值、GC 含量、读段参数）与孕妇 BMI 数据；
2. 预处理：对缺失 BMI 采用人群中位数填充，所有输入特征按照训练集参数执行标准化变换；
3. 概率计算：将标准化特征代入逻辑回归方程，计算染色体非整倍体预测概率 P；
4. 风险判定：根据临床选定的概率阈值进行判定，若 $P >$ 阈值则判定为高风险，建议进一步羊水穿刺确诊；低于阈值则判定为低风险。

最优概率阈值的选择需要结合临床对假阳性、假阴性的耐受程度：重视筛查灵敏度、降低漏检风险则选择较低阈值；重视特异度、减少不必要的有创检查则选择较高阈值。临床应用中可根据实际需求灵活调整。

5.8 模型局限性说明

本模型存在以下四点局限性，应用时需注意：1. 仅能输出「是否存在染色体非整倍体」的总体风险，无法区分具体是 13、18、21 哪一条染色体异常，若需明确具体类型需进一步开展靶向检测；2. 训练样本类别不平衡，阳性样本量偏少，模型泛化稳定性仍有提升空间，扩大阳性样本库可进一步提升性能；3. 线性模型无法捕捉特征之间的高阶非线性交互效应，对于复杂复合异常的判别能力有限；4. 阈值选择具有临床主观性，不存在唯一最优阈值，需结合具体应用场景的损失权重确定。

6 模型评价与推广

6.1 模型优势

1. ** 方法体系完整 **：从相关性分析、非线性检验、预测建模到分层优化、异常判别，形成了覆盖全部问题的完整分析链条；2. ** 多模型交叉验证 **：每个问题都采用多种建模方法横向对比，结论经过多重验证，稳健性强；3. ** 贴合临床机理 **：所有建模结论均能得到生物学与临床医学解释，不存在违背常识的黑箱结果；4. ** 可落地性强 **：最终输出显式公式与标准化流程，能够直接嵌入临床检测系统，无需复杂部署。

6.2 模型不足

1. 部分环节阳性样本量偏少，非线性模型稳定性受限；2. 缺乏外部独立验证集，模型泛化边界有待进一步确认；3. 未纳入孕产史、并发症等更多临床协变量，信息维度仍有拓展空间。

6.3 推广应用前景

本文构建的分层检测时点优化方案与女胎异常判别方法，可直接应用于无创产前检测临床实践，通过差异化采血时间推荐与多变量校正判别，能够有效降低肥胖人群假阴性率、减少女胎筛查假阳性，整体提升 NIPT 检测质量与卫生经济学效益。相关建模思路也可推广至其他染色体异常筛查、新生儿疾病筛查等类似场景。

参考文献

[1] 国家卫生健康委员会. 孕妇外周血胎儿游离 DNA 产前筛查与诊断技术规范 [S]. 北京: 中国标准出版社, 2020. [2] Hosmer D W, Lemeshow S. Applied Logistic Regression[M]. 3rd ed. New York: John Wiley Sons, 2000. [3] Breiman L. Random Forests[J]. Machine Learning, 2001, 45(1): 5-32. [4] Wood S N. Generalized Additive Models: An Introduction with R[M]. 2nd ed. Boca Raton: CRC Press, 2017. [5] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine Learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825-2830. [6] 张悦, 李娜, 王强. 孕妇 BMI 对无创产前检测胎儿游离 DNA 浓度的影响研究 [J]. 中华妇产科杂志, 2022, 57(8): 592-598. [7] Yang S Y, Zhang L, Wang H, et al. Combined Model-Based Prediction for Non-Invasive Prenatal Screening[J]. International Journal of Molecular Sciences, 2022, 23(23): 14990. [8] van Beek E, Janssen M, Oepkes D, et al. Fetal Fraction in Maternal Plasma: Determinants and Performance of NIPT[J]. Prenatal Diagnosis, 2017, 37(8): 769-777. [9] 刘芳, 陈明. 纵向数据混合效应模型在医学随访研究中的应用 [J]. 中国卫生统计, 2021, 38(2): 215-219. [10] 李华, 赵晓宇. 机器学习方法在出生缺陷筛查预测中的应用对比 [J]. 中国妇幼保健, 2023, 38(12): 2290-2294. [11] 王静, 林琳. 无创产前检测中 Z 值校正方法的研究进展 [J]. 国际遗传学杂志, 2022, 45(3): 245-251. [12] Bianchi D W, Wilkins-Haug L. Integration of Noninvasive Prenatal Testing Into Clinical Practice[J]. JAMA, 2014, 311(5): 507-508. [13] 中华医学会妇产科学分会产科学组. 无创产前检测技术临床应用专家共识 [J]. 中华妇产科杂志, 2016, 51(9): 641-645.

附录

附录 A　无统计学显著性的 Pearson 相关系数完整表

本附录对应正文表 2 的完整数值，列出所有与 Y 染色体浓度线性相关无统计学显著性（$P \geq 0.05$）的变量统计结果。

表 10: 无统计学显著性的 Pearson 相关系数完整表

变量名称	Pearson 相关系数	P 值
身高	-0.0619	0.0838
怀孕次数	-0.0579	0.1061
被过滤掉读段数的比例	0.0403	0.2601
18 号染色体的 GC 含量	-0.0177	0.6223
13 号染色体的 GC 含量	-0.0174	0.6282
生产次数	0.0077	0.8292
21 号染色体的 Z 值	0.0065	0.8553
GC 含量	0.0043	0.9054
21 号染色体的 GC 含量	0.0022	0.9509
Y 染色体的 Z 值	0.0001	0.9982

附录 B　MySQL 数据预处理与统计分析代码

本附录收录问题 2、问题 3 中用于原始数据清洗、分组统计、个体最早达标孕周计算的全部 MySQL 代码。

附录 B.1　BMI 与孕周交叉分组达标率统计

该代码用于按 BMI 四分位区间与孕周区间交叉分组，统计每组总样本数、达标样本数、达标率与 Y 染色体浓度均值，为分层分析提供基础统计数据。

```
SELECT
    t.`BMI分组`,
    t.`孕周分组`,
    COUNT(*) AS `总样本数`,
    SUM(CASE WHEN t.`Y染色体浓度` >= 0.04 THEN 1 ELSE 0 END) AS `达标样本数`,
    ROUND(SUM(CASE WHEN t.`Y染色体浓度` >= 0.04 THEN 1 ELSE 0 END) / COUNT(*), 4) AS `达标率`,
    ROUND(AVG(t.`Y染色体浓度`), 4) AS `Y染色体浓度均值`
FROM (
    SELECT
        `table1`.`孕妇BMI`,
        `table1`.`Y染色体浓度`,
        CASE
            WHEN `table1`.`孕妇BMI` >= 20.70 AND `table1`.`孕妇BMI` < 30.19 THEN '[20.70,30.19)
```

```
            WHEN `table1`.`孕妇BMI` >= 30.19 AND `table1`.`孕妇BMI` < 31.79 THEN '[30.19,31.79)
            WHEN `table1`.`孕妇BMI` >= 31.79 AND `table1`.`孕妇BMI` < 33.87 THEN '[31.79,33.87)
            WHEN `table1`.`孕妇BMI` >= 33.87 AND `table1`.`孕妇BMI` <= 43.91 THEN '[33.87,43.91]
            ELSE '-'
        END AS `BMI分组`,
        CASE
            WHEN CAST(SUBSTRING_INDEX(`table1`.`检测孕周`,'w',1) AS UNSIGNED) BETWEEN 11 AND 15
            WHEN CAST(SUBSTRING_INDEX(`table1`.`检测孕周`,'w',1) AS UNSIGNED) BETWEEN 16 AND 20
            WHEN CAST(SUBSTRING_INDEX(`table1`.`检测孕周`,'w',1) AS UNSIGNED) BETWEEN 21 AND 25
            WHEN CAST(SUBSTRING_INDEX(`table1`.`检测孕周`, 'w', 1)as unsigned )BETWEEN 26 AND 2
            ELSE '-'
        END AS `孕周分组`
    FROM `table1`
)t
WHERE `BMI分组` != '-' AND `孕周分组` != '-'
GROUP BY `BMI分组`, `孕周分组`
ORDER BY `BMI分组`, `孕周分组`;
```

附录 B.2 个体最早达标孕周计算（版本 1）

采用窗口函数标记孕妇内时序编号与达标记录编号，通过左关联保留所有孕妇，区分“存在达标记录”与“始终未达标”两类个体。

```
WITH all_rec AS (
    SELECT
        `孕妇代码`,
        `孕妇BMI`,
        `检测孕周`,
        `Y染色体浓度`,
        -- 孕妇内全局时序编号
        ROW_NUMBER() OVER(PARTITION BY `孕妇代码` ORDER BY `检测孕周` ASC) AS seq_all,
        -- 标记达标记录，并在孕妇内部对达标记录排序
        CASE WHEN `Y染色体浓度` >= 0.04 THEN
            ROW_NUMBER() OVER(PARTITION BY `孕妇代码` ORDER BY `检测孕周` ASC)
        ELSE NULL END AS seq_pass
    FROM table1
),
first_pass_info AS (
    SELECT
        `孕妇代码`,
        `孕妇BMI` AS `孕妇BMI`,
        `检测孕周` AS `个体最早达标孕周`,
        `Y染色体浓度` AS `首次达标浓度`
    FROM all_rec
```

```
    WHERE seq_pass = 1
),
first_any_record AS (
    SELECT
        `孕妇代码`,
        `孕妇BMI` AS base_bmi
    FROM all_rec
    WHERE seq_all = 1
)
SELECT
    COALESCE(fp.`孕妇代码`, fa.`孕妇代码`) AS `孕妇代码`,
    COALESCE(fp.`孕妇BMI`, fa.base_bmi) AS `孕妇BMI`,
    fp.`个体最早达标孕周`,
    fp.`首次达标浓度`,
    CASE
        WHEN fp.`孕妇代码` IS NULL THEN '始终未达标'
        ELSE '存在达标记录'
    END AS `达标状态`
FROM first_any_record fa
LEFT JOIN first_pass_info fp ON fa.`孕妇代码` = fp.`孕妇代码`
ORDER BY `孕妇代码`;
```

附录 B.3 个体最早达标孕周计算（版本 2）

通过提取全部孕妇基础信息与达标记录分别建表，左关联输出每个孕妇的首次达标情况，逻辑更简洁清晰。

```
WITH all_mother AS (
    SELECT DISTINCT
        `孕妇代码`,
        `孕妇BMI`
    FROM table1
),
qualified_records AS (
    SELECT
        `孕妇代码`,
        `检测孕周`,
        `Y染色体浓度`,
        ROW_NUMBER() OVER(
            PARTITION BY `孕妇代码`
            ORDER BY `检测孕周` ASC
        ) AS rn
    FROM table1
    WHERE `Y染色体浓度` >= 0.04
```

```
),
first_qualified AS (
    SELECT
        `孕妇代码`,
        `检测孕周` AS `个体最早达标孕周`,
        `Y染色体浓度` AS `首次达标浓度`
    FROM qualified_records
    WHERE rn = 1
)
SELECT
    a.`孕妇代码`,
    a.`孕妇BMI`,
    f.`个体最早达标孕周`,
    f.`首次达标浓度`,
    CASE
        WHEN f.`孕妇代码` IS NULL THEN '始终未达标'
        ELSE '存在达标记录'
    END AS `达标状态`
FROM all_mother a
LEFT JOIN first_qualified f
    ON a.`孕妇代码` = f.`孕妇代码`;
```

附录 B.4 个体最早达标孕周计算（版本 3）

包含未达标孕妇兜底逻辑，确保所有孕妇均输出一条记录，未达标个体保留基础信息，孕周与浓度字段为空。

```
WITH pass_record AS (
    SELECT
        `孕妇代码`,
        `孕妇BMI`,
        `检测孕周`,
        `Y染色体浓度`,
        ROW_NUMBER() OVER(
            PARTITION BY `孕妇代码`
            ORDER BY `检测孕周` ASC
        ) AS rn
    FROM table1
    WHERE `Y染色体浓度` >= 0.04 or `孕妇代码` NOT IN (
        SELECT DISTINCT `孕妇代码` FROM table1 WHERE `Y染色体浓度` >= 0.04
    )
),
each_earliest_pass AS (
    SELECT * FROM pass_record WHERE rn = 1
```

```
)
SELECT
    `孕妇代码`,
    `孕妇BMI`,
    `检测孕周` AS 个体最早达标孕周,
    `Y染色体浓度` AS 首次达标浓度
FROM each_earliest_pass;
```

附录 C　Python 建模源代码

附录 C.1　问题 1 相关性分析与纵向混合效应建模代码

```
import pandas as pd
import numpy as np
from scipy.stats import pearsonr
import warnings
warnings.filterwarnings("ignore")

# 读取数据
df = pd.read_excel("附件.xlsx", sheet_name=0)
df.columns = df.columns.str.strip()

# Pearson相关性分析
target = "Y染色体浓度"
features = df.columns.drop(["孕妇代码", target]).tolist()
result = []
for col in features:
    valid = df[[col, target]].dropna()
    r, p = pearsonr(valid[col], valid[target])
    result.append({"变量": col, "相关系数r": r, "P值": p})
res_df = pd.DataFrame(result).sort_values("相关系数r", key=abs, ascending=False)
print(res_df)
```

附录 C.2　问题 4 女胎染色体异常判别完整代码

```
import pandas as pd
import numpy as np
import warnings
from sklearn.model_selection import train_test_split, StratifiedKFold, RandomizedSearchCV
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_auc_score
import xgboost as xgb
warnings.filterwarnings("ignore")
```

```
FILE_PATH = r"C:\Users\lenovo\Desktop\C题\附件.xlsx"
df_raw = pd.read_excel(FILE_PATH, sheet_name=1)
df_raw.columns = df_raw.columns.str.strip()

# 构造二分类标签
df_raw["y_label"] = df_raw["染色体的非整倍体"].apply(lambda s: 1 if pd.notna(s) else 0)

# 完整特征池
feature_pool = [
    "13号染色体的Z值", "18号染色体的Z值", "21号染色体的Z值", "X染色体的Z值",
    "13号染色体的GC含量", "18号染色体的GC含量", "21号染色体的GC含量",
    "原始读段数", "在参考基因组上比对的比例", "重复读段的比例", "唯一比对的读段数",
    "孕妇BMI"
]

df_use = df_raw[feature_pool + ["y_label"]].copy()
df_use["孕妇BMI"] = df_use["孕妇BMI"].fillna(df_use["孕妇BMI"].median())

X_raw = df_use[feature_pool]
y = df_use["y_label"]
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X_raw)

seed_list = [6, 10, 22, 33, 42]
result_store = []
imp_sum = np.zeros(len(feature_pool))

pos_num = np.sum(y == 1)
neg_num = np.sum(y == 0)
weight = neg_num / pos_num

for seed in seed_list:
    X_train, X_test, y_train, y_test = train_test_split(
        X_scaled, y, test_size=0.25, random_state=seed, stratify=y
    )
    # 逻辑回归
    lr = LogisticRegression(max_iter=2000, class_weight="balanced", random_state=seed)
    lr.fit(X_train, y_train)
    lr_pred = lr.predict_proba(X_test)[:, 1]
    lr_auc = roc_auc_score(y_test, lr_pred)

    # XGBoost网格搜索
```

```
    param_grid = {
        "max_depth": [2, 3],
        "learning_rate": [0.01, 0.05],
        "n_estimators": [40, 70],
        "subsample": [0.7, 0.8]
    }
    kfold = StratifiedKFold(n_splits=5, shuffle=True, random_state=seed)
    xgb_base = xgb.XGBClassifier(
        random_state=seed, eval_metric="logloss", scale_pos_weight=weight
    )
    search = RandomizedSearchCV(
        xgb_base, param_grid, n_iter=15, cv=kfold, scoring="roc_auc", random_state=seed
    )
    search.fit(X_train, y_train)
    best_xgb = search.best_estimator_
    xgb_pred = best_xgb.predict_proba(X_test)[:, 1]
    xgb_auc = roc_auc_score(y_test, xgb_pred)

    result_store.append({
        "随机种子": seed, "逻辑回归AUC": lr_auc,
        "XGB最优AUC": xgb_auc, "最优参数": search.best_params_
    })
    imp_sum += best_xgb.feature_importances_

# 输出结果
result_df = pd.DataFrame(result_store)
print("==== 多随机种子AUC结果 ====")
print(result_df)

imp_avg = imp_sum / len(seed_list)
imp_df = pd.DataFrame({"特征": feature_pool, "平均重要度": imp_avg})
imp_df = imp_df.sort_values("平均重要度", ascending=False)
print("\n==== 特征重要度排序 ====")
print(imp_df)

# 最终逻辑回归方程
final_lr = LogisticRegression(max_iter=2000, class_weight="balanced", random_state=10)
final_lr.fit(X_scaled, y)
coef = final_lr.coef_[0]
intercept = final_lr.intercept_[0]
expr = f"logit(P) = {intercept:.4f}"
for idx, name in enumerate(feature_pool):
    c = coef[idx]
```

```
    sign = "+" if c >= 0 else ""
    expr += f" {sign}{c:.4f} × {name}"
print("\n==== 回归方程 ====")
print(expr)
```